МИНОБРНАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ

«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ
УНИВЕРСИТЕТ ПЕТРА ВЕЛИКОГО»

Институт компьютерных наук и кибербезопасности

Высшая школа технологий искусственного интеллекта

Направление: 02.03.01 «Математика и компьютерные науки»

Курсовое проектирование по дисциплине.
«Функциональное программирование»
на тему:
«Рекомендательная система фильмов при помощи модели,
основанной на косинусной мере сходства»

Студент группы 5130201/40101 _____ Резчик Д.О.

Преподаватель _____ Моторин Д.Е.

«____» _____ 2026 г.

Санкт-Петербург
2026

Содержание

1 Техническое задание 3
1.1 Основание для выполнения работы . . . 3
1.2 Исполнитель и соисполнители работы . . . 3
1.3 Цели, задачи и исходные данные . . . 3
1.3.1 Цель работы . . . 3
1.3.2 Задачи работы . . . 3
1.3.3 Исходные данные . . . 4
1.4 Основное содержание работы . . . 4
1.4.1 Модули приложения . . . 4
1.5 Основные требования к выполнению работы . . . 5
1.5.1 Назначение разрабатываемого программного комплекса . . . 5
1.6 Технические характеристики по назначению . . . 5
1.6.1 Функциональные требования . . . 5
1.7 Этапы и сроки выполнения работы . . . 7
1.7.1 Перечень этапов . . . 7
1.7.2 Диаграмма Ганта . . . 7
1.8 Результаты работы . . . 7

Список литературы 9

1 Техническое задание

1.1 Основание для выполнения работы

Основанием для выполнения работы является учебный план направления 02.03.01 «Математика и компьютерные науки» Высшей школы технологий искусственного интеллекта Института компьютерных наук и кибербезопасности Санкт-Петербургского Политехнического университета Петра Великого, который предусматривает выполнение курсовой работы по дисциплине «Функциональное программирование».

1.2 Исполнитель и соисполнители работы

Исполнитель: студент учебной группы 5130201/40101 Резчик Денис Олегович.

1.3 Цели, задачи и исходные данные

1.3.1 Цель работы

Целью работы является создание рекомендательной системы подбора фильмов на основе анализа описаний фильмов с использованием методов машинного обучения (TF-IDF векторизация и косинусная мера сходства).

1.3.2 Задачи работы

1. Изучить набор данных Movie Dataset, выбранных для построения модели.
2. Реализовать модуль загрузки данных из CSV файла (CSVLoader).
3. Реализовать модуль предобработки текста: токенизация, удаление стоп-слов, нормализация текста.
4. Реализовать модуль TF-IDF векторизации описаний фильмов.
5. Обучить модель на основе косинусной меры сходства. Реализовать сохранение векторов и весов в отдельные файлы.
6. Реализовать консольный интерфейс с двумя способами ввода интересующих пользователя фильмов: интерактивный ввод названий фильмов в консоль и загрузка списка фильмов из текстового файла.
7. Реализовать модуль оценки качества модели (ModelEvaluation) с вычислением метрик сходства.
8. Реализовать систему логирования действий пользователя и системных событий в текстовый файл.
9. Обеспечить систему обработки ошибок: отсутствие файлов, неправильный ввод.
10. Написать набор тестов с использованием QuickCheck.

1.3.3 Исходные данные

Исходными данными для выполнения данной работы является набор данных о фильмах «Movie Dataset», опубликованный на платформе Kaggle. Он представляет собой CSV-файл с описанием фильмов. Основные используемые признаки:

Признак	Тип	Описание
id	Int	Уникальный идентификатор фильма
original_title	String	Оригинальное название фильма
overview	String	Описание сюжета фильма
keywords	[String]	Ключевые слова, характеризующие фильм
genres	[String]	Жанры фильма
popularity	Double	Метрика популярности фильма

Таблица 1. Описание основных признаков датасета

1.4 Основное содержание работы

Приложение представляет собой консольную систему рекомендаций фильмов, построенную на основе TF-IDF векторизации описаний фильмов и вычисления косинусной меры сходства между ними.

1.4.1 Модули приложения

1. CSVLoader — загружает данные из CSV файла, сохраняет информацию о фильмах в структурированном виде.
2. Preprocessing — модуль обработки текста: преобразование регистра, удаление пунктуации, удаление стоп-слов для подготовки текста к анализу моделью.
3. TFIDFVectorizer — построение словаря из описаний фильмов, вычисление TF-IDF векторов для каждого фильма с использованием sparse представления.
4. Recommender — поиск подходящих фильмов с помощью косинусной меры сходства между TF-IDF векторами.
5. ModelEvaluation — вычисление метрик качества модели: схожесть описаний фильмов одного жанра, разреженность векторов, покрытие датасета.
6. ModelPersistence — кеширование предобученной модели. Сохраняет словарь, IDF-веса и TF-IDF профили фильмов в CSV-файлы для быстрой загрузки при последующих запусках.
7. Logger — логирование основных операций системы в файл app.log: загрузка данных, построение модели, запросы пользователя, ошибки.
8. UI — интерактивное меню, ввод параметров, обработка неправильного ввода информации, вывод результатов рекомендаций в консоль.

1.5 Основные требования к выполнению работы

1.5.1 Назначение разрабатываемого программного комплекса

Разрабатываемый программный комплекс предназначен для рекомендации фильмов на основе анализа их описаний. Пользователь выбирает интересующие его фильмы, а система находит и рекомендует похожие фильмы, используя методы векторизации текста и вычисления мер сходства.

1.6 Технические характеристики по назначению

Программное обеспечение должно обеспечить следующие технические характеристики:

1. Среднее косинусное сходство между фильмами одного жанра на валидационной выборке — не менее 0,3 (30%).
2. Время загрузки датасета и построения модели TF-IDF на первый запуск — не более 5 минут на стандартном персональном компьютере.
3. Время загрузки кешированной модели (словарь, IDF-веса, векторы) при повторных запусках — не более 2 секунд.
4. Время обработки запроса пользователя (поиск рекомендаций для 1-5 выбранных фильмов) — не более 10 секунд.
5. Размер кешированной модели (CSV-файлы) — не более 500 МБ.
6. Покрытие датасета (процент успешно обработанных фильмов) — не менее 95%.

1.6.1 Функциональные требования

Загрузка и предобработка данных

1. Приложение должно читать CSV файл с данными о фильмах.
2. Для каждого фильма извлечь: ID, название, описание (overview), ключевые слова.
3. Применить Preprocessing: нормализация регистра, удаление пунктуации, токенизация, удаление стоп-слов.
4. Результаты предобработки должны использоваться для построения TF-IDF модели.

Обучение модели

1. Датасет делится на обучающую (70%), валидационную (15%) и тестовую (15%) выборки.
2. На обучающей выборке:
   - Строится словарь (Vocabulary) из уникальных слов.
   - Вычисляются значения IDF (Inverse Document Frequency) для каждого слова.
3. На валидационной выборке:

- Вычисляются TF-IDF векторы для фильмов.
- Вычисляются метрики внутригруппового сходства (intra-film similarity).
- Проверяется адекватность разреженности векторов.

4. На тестовой выборке:
   - Вычисляются TF-IDF векторы.
   - Проводится итоговая оценка качества модели.
   - Вычисляются метрики: среднее сходство, покрытие датасета, разреженность векторов.
5. Предобработка текстовых признаков: нормализация регистра, удаление пунктуации, токенизация, удаление стоп-слов.
6. Построенная модель (словарь, IDF-веса, TF-IDF векторы фильмов) сохраняется в CSV-файлы для дальнейшей загрузки при использовании приложения.

Рекомендация фильмов

1. Пользователь выбирает один или несколько фильмов по названию.
2. Система вычисляет средний TF-IDF вектор выбранных фильмов.
3. Для каждого остального фильма вычисляется косинусная мера сходства с вектором пользователя.
4. Система сортирует фильмы по значению косинусной меры в убывающем порядке.
5. Выводит топ-10 рекомендованных фильмов с указанием оценки сходства (0-100%).

Оценка качества модели

1. Вычислить среднее внутригрупповое сходство (для фильмов одного жанра).
2. Вычислить среднюю разреженность векторов.
3. Вычислить покрытие датасета (процент обработанных фильмов).
4. Вывести метрики на экран при запуске.

Обработка ошибок и логирование

1. Обработка некорректного ввода пользователя (пустой текст, несуществующие ID).
2. Обработка отсутствия файлов (CSV, кешированная модель).
3. Вывод понятных сообщений об ошибках.
4. Все действия должны логироваться в app.log с временными метками.

1.7 Этапы и сроки выполнения работы

1.7.1 Перечень этапов

1. Этап 1. Выбор датасета и составление технического задания (до 08.09.2026).
   Выбор Movie Dataset, анализ структуры, разработка технического задания.
2. Этап 2. Проектирование архитектуры (до 09.09.2026).
   Диаграмма типов и модулей, описание структур данных, обоснование выбора библиотек.
3. Этап 3. Разработка загрузки данных и предобработки текста (до 10.09.2026).
   Реализация CSVLoader, Preprocessing модулей.
4. Этап 4. Разработка TF-IDF и оценка качества (до 10.09.2026).
   Реализация TFIDFVectorizer и ModelEvaluation модулей.
5. Этап 5. Реализация рекомендаций и сохранения модели (до 11.09.2026).
   Реализация Recommender и ModelPersistence модулей.
6. Этап 6. Разработка UI и логирования (до 11.09.2026).
   Реализация UI и Logger модулей, интеграция компонентов.
7. Этап 7. Тестирование и документация (до 12.09.2026).
   Написание тестов QuickCheck, разработка документации.

1.7.2 Диаграмма Ганта



Рис. 1. Диаграмма Ганта

1.8 Результаты работы

1. Согласованное техническое задание.
2. Описание архитектуры проекта: диаграмма типов и модулей, описание структур данных.
3. Работающие модули обработки данных: CSVLoader, Preprocessing, TFIDFVectorizer.
4. Модуль оценки качества модели (ModelEvaluation) с вычисленными метриками.
5. Модуль сохранения и загрузки модели (ModelPersistence) с поддержкой кеширования.
6. Работающее консольное приложение movie-recommender с возможностью получения рекомендаций по заданным фильмам.

7. Система логирования с записью всех событий в app.log.
8. Набор тестов QuickCheck для проверки корректности основных функций.
9. Отчёт о выполненной курсовой работе с описанием выполнения работы и результатов.

Список литературы

[1] Датасет, использованный для обучения модели «Movie Dataset» [Электронный ресурс]. URL: https://www.kaggle.com/datasets/figolm10/movie-dataset/data (Дата обращения: 25.08.2026)